Laporan Tugas Besar 1
Jaringan Syaraf Tiruan



Mata Kuliah	**Jaringan Syaraf Tiruan**
Dosen Pengampu	**Matahari Bhakti Nendya, S.Kom., M. T**
Disusun Oleh	71241153 Felix Benedictus Setiawan 71241169 Rivano Putra Samudra 71241162 Dita Pranata Tandisau 71241115 Devon Novan Surya Putra

PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS KRISTEN DUTA WACANA
YOGYAKARTA
2026

DAFTAR ISI

I. Masalah dan Tujuan....3
A. Masalah....3
B. Tujuan....3
II. Dataset dan Kaitannya dengan Tugas 1....3
A. Dataset....3
B. Fitur & Target....4
C. Kaitan dengan Tugas 1....4
III. Artikel dan Kode Pendukung....4
A. Artikel ilmiah....4
B. Kode dan Dokumentasi Teknis....5
C. Penggunaan Bantuan AI....5
IV. Model Neuron dan Aturan Pembelajaran....6
A. Model Neuron....6
B. Perceptron....6
C. ADALINE (Delta Rule)....6
D. Perbedaan Model....6
V. Persiapan Data dan Rancangan Eksperimen....7
A. Pembagian Data....7
B. Standardisasi Data....7
C. Rancangan Eksperimen....7
VI. Hasil....8
A. Tabel Konfigurasi....8
B. Kondisi Epoch 10, 30, 50....8
C. Confusion Matrix....9
D. Kurva Pelatihan dan Decision Boundary....10
VII. Pembahasan dan Keterbatasan....12
A. Pembahasan....12
- Perceptron....12
- ADALINE....12
B. Keterbatasan....12
- Label dibentuk dari ambang usia 40 tahun, sehingga pelanggan berusia di sekitar 40 sulit dibedakan oleh fitur belanja....13
C. Perbandingan....13
VIII. Kesimpulan....13
IX. Daftar Pustaka....14

I. Masalah dan Tujuan

A. Masalah

Segmentasi pelanggan sering memakai usia sebagai salah satu dasar pengelompokan. Pada penelitian ini, kasus tersebut dirumuskan sebagai masalah *supervised learning* (pembelajaran terawasi) berupa klasifikasi biner: memprediksi apakah seorang pelanggan termasuk kelompok Muda atau Tua berdasarkan dua fitur, yaitu *Annual Income* dan *Spending Score*.

Perceptron dan ADALINE adalah neuron tunggal dengan batas keputusan linear, sehingga keduanya hanya dapat memisahkan kelas dengan sebuah garis lurus. Pertanyaan utamanya adalah apakah kedua fitur tersebut cukup untuk memisahkan kelompok usia secara linear, dan bagaimana performa kedua model pada data ini.

B. Tujuan

- Mengimplementasikan Perceptron dan ADALINE secara mandiri menggunakan Python dan NumPy.
- Menganalisis pengaruh standardisasi dan variasi *learning rate* (0,001; 0,01; 0,1) terhadap proses pelatihan dan akurasi kedua model.
- Membandingkan performa Perceptron dan ADALINE berdasarkan akurasi uji, error atau loss, dan *confusion matrix*.
- Menilai apakah data menunjukkan indikasi dapat dipisahkan secara linear, serta menjelaskan perbedaan cara kedua model memperbarui bobot.

II. Dataset dan Kaitannya dengan Tugas 1

A. Dataset

- Dataset yang digunakan adalah *Mall_Customer.csv* yang berisi data 200 pelanggan pusat perbelanjaan.Dataset ini telah dipastikan bersih, yang berarti tidak terdapat *missing value* maupun data duplikasi. Sumber: https://www.kaggle.com/code/ahmedwaleed1903/mall-customer.
  Atribut dalam dataset

Atribut	**Keterangan**	**Dipakai**
CustomerID	Pengenal Unik Pelanggan	Tidak
Gender	Jenis Kelamin Pelanggan	Tidak
Age	Usia Pelanggan	Target Klasifikasi
Annual Income (k$)	Pendapatan	Fitur
Spending Score (1-100)	Skor Belanja Pelanggan	Fitur

Tabel 1. Komponen Dataset

B. Fitur & Target

- Fitur Input (X) : Annual Income (k$) dan Spending Score (1-100). Kedua fitur ini dipilih karena merepresentasikan secara langsung daya beli dan perilaku konsumtif pelanggan, yang menjadi metrik utama dalam segmentasi pasar ritel.
- Target Klasifikasi (y) :
    1. 1 (Muda) Jika age < 40 tahun
    2. -1 (Tua) Jika age >= 40 tahun
- Alasan Pemilihan Target: Ambang batas umur 40 tahun digunakan karena secara demografis sering menjadi titik pemisah psikologis dan perilaku belanja antar generasi. Kelompok "Muda" ditetapkan sebagai kelas positif (+1) dengan asumsi bahwa demografi ini merupakan target pasar sasaran utama yang perilakunya ingin dipelajari oleh model.
- Distribusi Kelas 116 Muda = 58%, 84 Tua = 42%

C. Kaitan dengan Tugas 1

Pada Tugas 1, telah dilakukan analisis eksplorasi data (EDA) dan segmentasi pelanggan menggunakan dataset ini. Pada Tugas Besar 1 ini, data tersebut digunakan kembali untuk menguji sejauh mana model neuron tunggal linear (*supervised learning* klasifikasi biner seperti Perceptron dan ADALINE) mampu mengenali dan memisahkan pola usia berdasarkan dua variabel perilaku belanja tersebut.

III. Artikel dan Kode Pendukung

A. Artikel ilmiah

Sumber	Kontribusi
Rosenblatt, F. (1958). *The perceptron: A probabilistic model for information storage and organization in the brain*. Psychological Review. DOI: 10.1037/h0042519	Menjadi acuan dasar arsitektur model Perceptron. Referensi ini mendasari keputusan desain bahwa pembaruan parameter (bobot dan bias) hanya dilakukan ketika model melakukan kesalahan klasifikasi pada suatu sampel.
Widrow, B., & Hoff, M. E. (1960). *Adaptive switching circuits*. IRE WESCON Convention Record. URL: https://isl.stanford.edu/~widrow/papers/c1960adaptiveswitching.pdf	Menjadi acuan dasar ADALINE dan *Delta Rule*. Mengarahkan keputusan desain bahwa pembaruan bobot harus dihitung dari galat (*error*) keluaran linear sebelum fungsi aktivasi untuk meminimalkan *Mean Squared Error* (MSE).
Gupta, V., dkk. (2025). *Customer Segmentation using Machine Learning*.	Artikel kasus ini menegaskan bahwa fitur *Annual Income* dan *Spending Score* merupakan variabel perilaku kunci yang

International Journal of Innovative Research in Technology (IJIRT), 11(11). URL: https://ijirt.org/publishedpaper/IJIRT176215_PAPER.pdf	sangat efektif untuk memahami preferensi pelanggan. Hal ini memperkuat dasar pemilihan kedua fitur tersebut untuk diuji keterpisahan linearnya pada eksperimen ini.

Tabel 2. Artikel Ilmiah yang dipakai

B. Kode dan Dokumentasi Teknis

Sumber Dokumentasi	Bagian yang diadaptasi	Perubahan yang dilakukan
Raschka, S. *mlxtend: Adaline (Adaptive Linear Neuron)*. URL: https://rasbt.github.io/mlxtend/user_guide/classifier/Adaline/	Konsep struktur algoritma *batch gradient descent* dan pola perulangan (*loop*) *epoch*.	Algoritma diimplementasikan *from scratch* tanpa memanggil fungsi mlxtend. Perubahan desain: bobot diinisialisasi murni nol, *error* linear diekstrak secara manual untuk analisis, dan nilai objektif (MSE) direkam tepat sebelum pembaruan parameter.
Pedregosa, F., et al. *Scikit-Learn API Reference*. URL: https://scikit-learn.org/stable/api/index.html	Pemanggilan fungsi train_test_split, StandardScaler, accuracy_score, confusion_matrix, dan classification_report.	Dipakai langsung tanpa modifikasi untuk tahap prapemrosesan dan evaluasi metrik. Scikit-Learn sama sekali tidak digunakan sebagai *solver* untuk melatih model utama.

Tabel 3. Kode & Dokumentasi Teknis yang dipakai

C. Penggunaan Bantuan AI

Kelompok memakai bantuan AI (gemini, claude) untuk membantu membuat laporan ini, seperti memberikan saran format struktur dokumen dan sebagai rekan diskusi untuk memastikan narasi pembahasan sesuai dengan hasilnya. Implementasi Perceptron, ADALINE, eksperimen yang ada di notebook juga menggunakan bantuan AI untuk kodingnya. Cara verifikasi:

1. Seluruh kode dijalankan ulang
2. Angka pada laporan dicocokkan dengan keluaran notebook
3. Narasi pembahasan diperiksa ulang (tabel, grafik hasil)
4. Rumus dan aturan pembaruan pada kode dicocokkan dengan ketentuan panduan penugasan
5. Artikel dan dokumentasi pada daftar pustaka diperiksa sumbernya

IV. Model Neuron dan Aturan Pembelajaran

A. Model Neuron

Kedua model (Perceptron & ADALINE) memakai 1 neuron dengan 2 input / masukan yaitu x1 = Annual Income dan x2 = Spending Score, berikut detailnya:

$z = w_1x_1 + w_2x_2 + b = w^Tx + b$

$\hat{y} = +1$ jika $z \geq 0$, dan -1 jika $z < 0$

Bobot w menentukan pengaruh tiap fitur, bias b menggeser batas keputusan, dan fungsi aktivasi *bipolar step* mengubah z menjadi label −1 atau +1. Batas keputusannya berupa garis lurus $w_1x_1 + w_2x_2 + b = 0$. Pada kedua model, bobot dan bias awal bernilai nol, dan urutan data tetap (tidak diacak) pada setiap epoch.

B. Perceptron

Untuk setiap sampel (xi, yi) secara berurutan:

$\Delta = \eta\ (y_i - \hat{y}_i)$

$w \leftarrow w + \Delta \cdot x_i$

$b \leftarrow b + \Delta$

Karena y_i dan $\hat{y}_i$ bernilai ±1, pembaruan hanya terjadi ketika prediksi salah ($y_i - \hat{y}_i = \pm 2$, sedangkan jika benar nilainya 0). Jumlah pembaruan akibat salah klasifikasi dicatat setiap epoch, dan pelatihan berhenti lebih awal jika satu epoch tidak menghasilkan error.

C. ADALINE (Delta Rule)

ADALINE memakai keluaran linear z, bukan keluaran ambang, untuk menghitung error:

$e_i = y_i - z_i$

$J = (1/2n)\ \Sigma\ (y_i - z_i)^2$

Pembaruan dilakukan dengan batch gradient descent pada seluruh n sampel latih setiap epoch:

$w \leftarrow w + \eta \cdot X^Te / n$

$b \leftarrow b + \eta \cdot \text{mean}(e)$

Fungsi ambang hanya dipakai pada saat prediksi. Pada implementasi ini, nilai yang dilaporkan adalah **MSE = (1/n) Σ$(y_i - z_i)^2$**, dan MSE dihitung sebelum pembaruan bobot di setiap epoch.

D. Perbedaan Model

	Perceptron	ADALINE
Error	y − ŷ (keluaran ambang)	y − z (keluaran linear)
Pembaruan	Per sampel, jika salah	Per batch, semua sampel
Dicatat	Jumlah pembaruan akibat salah klasifikasi per epoch	MSE

Tabel 4. Perbedaan antar Model

Perhitungan manual dua langkah pembaruan untuk setiap model disajikan pada notebook.

V. Persiapan Data dan Rancangan Eksperimen

A. Pembagian Data

Data dibagi 80:20 secara stratifikasi menurut kelas dengan *random seed* 42, menghasilkan 160 data latih dan 40 data uji (23 Muda dan 17 Tua). Pembagian yang sama dipakai untuk kedua model.

B. Standardisasi Data

Fitur distandardisasi dengan z-score: $x' = (x - \mu) / \sigma$. Nilai μ dan σ dihitung **hanya dari data latih**, lalu diterapkan pada data uji, sehingga tidak ada informasi data uji yang masuk ke proses pelatihan.

C. Rancangan Eksperimen

Semua konfigurasi dilatih masing-masing 50 epoch dengan bobot dan bias awalnya 0 serta urutan sampel yang tetap. Konfigurasi ditetapkan sebelum melihat hasil data uji. Berikut tabel konfigurasinya:

No	Model	η	Epoch	Stardardisasi
1 - 3	Perceptron	0,001; 0,01; 0,1	50	Ya
4 - 6	ADALINE	0,001; 0,01; 0,1	50	Ya
7	Perceptron	0,01	50	Tidak
8	ADALINE	0,01	50	Tidak

Tabel 5. Tabel Konfigurasi

Konfigurasi no 7 dan 8 memakai pembagian data, inisialisasi, dan urutan sampel yang sama dengan konfigurasi lain, sehingga pengaruh skala fitur dapat dibandingkan. Seluruh konfigurasi dilaporkan dan data uji tidak dipakai untuk memilih parameter. Evaluasi meliputi akurasi latih dan uji, *confusion matrix* (kelas positif: Muda), precision, recall, F1-score, serta loss pada epoch ke-10, 30, dan 50. Akurasi kelas mayoritas dipakai sebagai pembanding (*baseline*).

VI. Hasil

A. Tabel Konfigurasi

	Model	LR	Standardisasi	Akurasi Uji	Error / MSE Akhir
0	Perceptron	0.001	Ya	57.50%	5.800000e+01
1	ADALINE	0.001	Ya	60.00%	9.791000e-01
2	Perceptron	0.010	Ya	57.50%	5.800000e+01
3	ADALINE	0.010	Ya	60.00%	8.601000e-01
4	Perceptron	0.100	Ya	57.50%	5.800000e+01
5	ADALINE	0.100	Ya	60.00%	7.776000e-01
6	Perceptron	0.010	Tidak	65.00%	8.200000e+01
7	ADALINE	0.010	Tidak	42.50%	3.690355e+178

```
=== HASIL PERCEPTRON ===
Bobot akhir (w): [ 0.00155284 -0.00173722]
Bias akhir (b): 0.0200
Total error klasifikasi di Epoch 50: 58
Akurasi Data Uji (Test): 57.50%

=== HASIL ADALINE ===
Bobot akhir (w): [0.02614186 0.17329555]
Bias akhir (b): 0.0642
MSE di Epoch 50: 0.8601
Akurasi Data Uji (Test): 60.00%
```

Gambar 1. Hasil 8 konfigurasi pada epoch ke-50

Perceptron menghasilkan hasil yang sama untuk semua η, sedangkan ADALINE mencapai akurasi uji 60% dengan MSE yang berbeda untuk η = 0,001; 0,01; dan 0,1.

B. Kondisi Epoch 10, 30, 50

Perbandingan Epoch 10 / 30 / 50

	Model	LR	Std	Loss@10	AkLatih@10	Loss@30	AkLatih@30	Loss@50	AkLatih@50
0	Perceptron	0.001	Ya	6.000000e+01	58.13%	5.800000e+01	58.13%	5.800000e+01	58.13%
1	Perceptron	0.010	Ya	6.000000e+01	58.13%	5.800000e+01	58.13%	5.800000e+01	58.13%
2	Perceptron	0.100	Ya	6.000000e+01	58.13%	5.800000e+01	58.13%	5.800000e+01	58.13%
3	ADALINE	0.001	Ya	9.959999e-01	66.25%	9.873669e-01	66.25%	9.790754e-01	66.25%
4	ADALINE	0.010	Ya	9.629354e-01	66.25%	9.012127e-01	66.25%	8.600604e-01	66.25%
5	ADALINE	0.100	Ya	8.105326e-01	66.25%	7.781049e-01	66.88%	7.776347e-01	66.88%
6	Perceptron	0.010	Tidak	8.000000e+01	57.50%	8.100000e+01	59.38%	8.200000e+01	63.12%
7	ADALINE	0.010	Tidak	6.825619e+31	41.88%	1.587103e+105	41.88%	3.690355e+178	41.88%

Baseline kelas mayoritas (1): akurasi uji = 57.50%

Gambar 2. Loss dan Akurasi latih pada epoch ke-10, 30, 50

Jumlah pembaruan Perceptron turun dari 60 (epoch 10) menjadi 58 (epoch 30, 50), sedangkan MSE ADALINE menurun pada semua η dengan standardisasi.

C. Confusion Matrix

```
CONFUSION MATRIX: PERCEPTRON
Benar tebak Muda (1) : 23 | Salah tebak jadi Tua (-1): 0
Salah tebak jadi Muda (1): 17 | Benar tebak Tua (-1) : 0

Laporan Klasifikasi Perceptron:
              precision    recall  f1-score   support

    Muda (1)       0.57      1.00      0.73        23
    Tua (-1)       0.00      0.00      0.00        17

    accuracy                           0.57        40
   macro avg       0.29      0.50      0.37        40
weighted avg       0.33      0.57      0.42        40
```

Gambar 3. Confusion Matriks Perceptron

```
 CONFUSION MATRIX: ADALINE
Benar tebak Muda (1) : 16 | Salah tebak jadi Tua (-1): 7
Salah tebak jadi Muda (1): 9 | Benar tebak Tua (-1) : 8

Laporan Klasifikasi ADALINE:
              precision    recall  f1-score   support

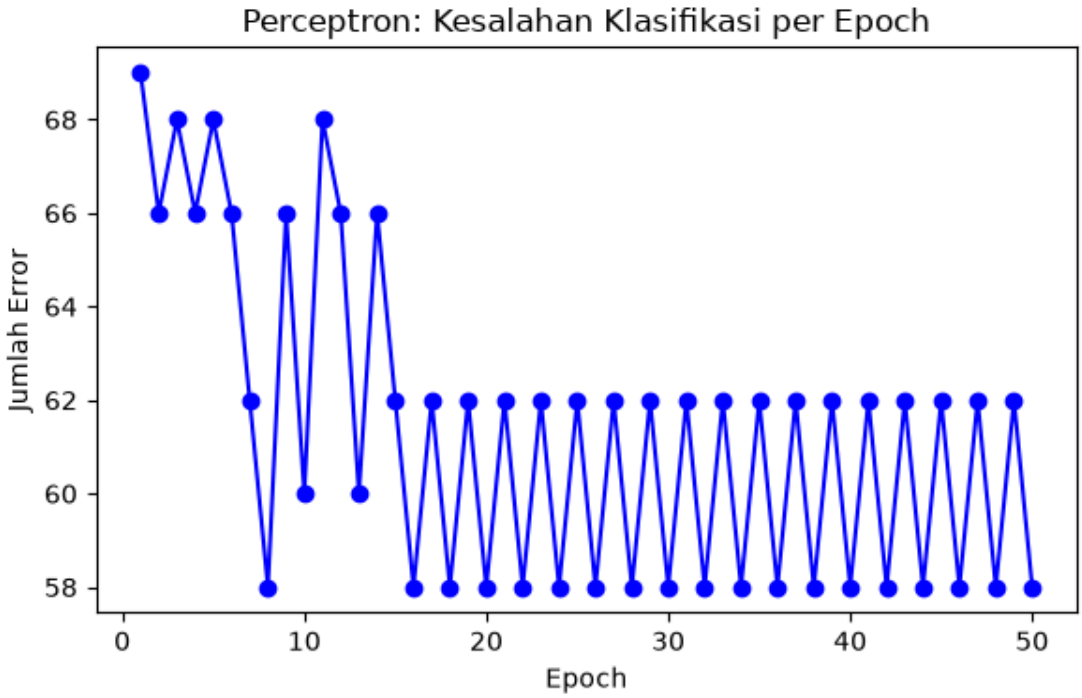
    Muda (1)       0.64      0.70      0.67        23
    Tua (-1)       0.53      0.47      0.50        17

    accuracy                           0.60        40
   macro avg       0.59      0.58      0.58        40
weighted avg       0.59      0.60      0.60        40
```

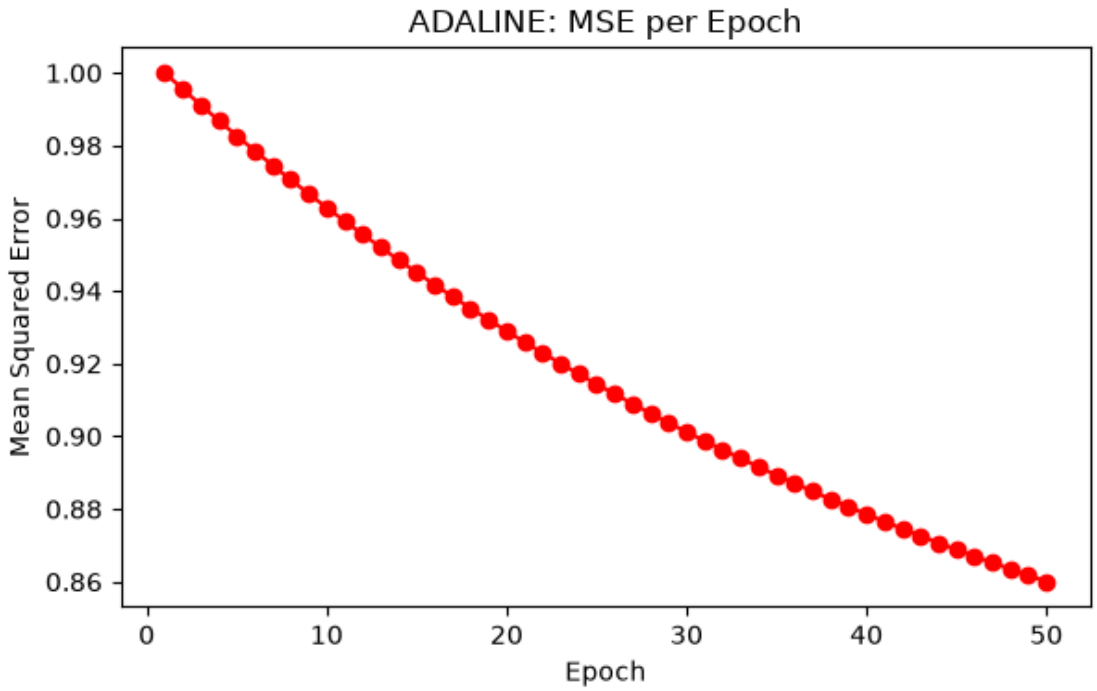
Gambar 4. Confusion Matrix ADALINE

Perceptron memprediksi seluruh 40 sampel uji sebagai Muda (23 benar, 17 salah), sedangkan ADALINE memprediksi kedua kelas dengan recall Muda 0,70 dan recall Tua 0,47.

D. Kurva Pelatihan dan Decision Boundary

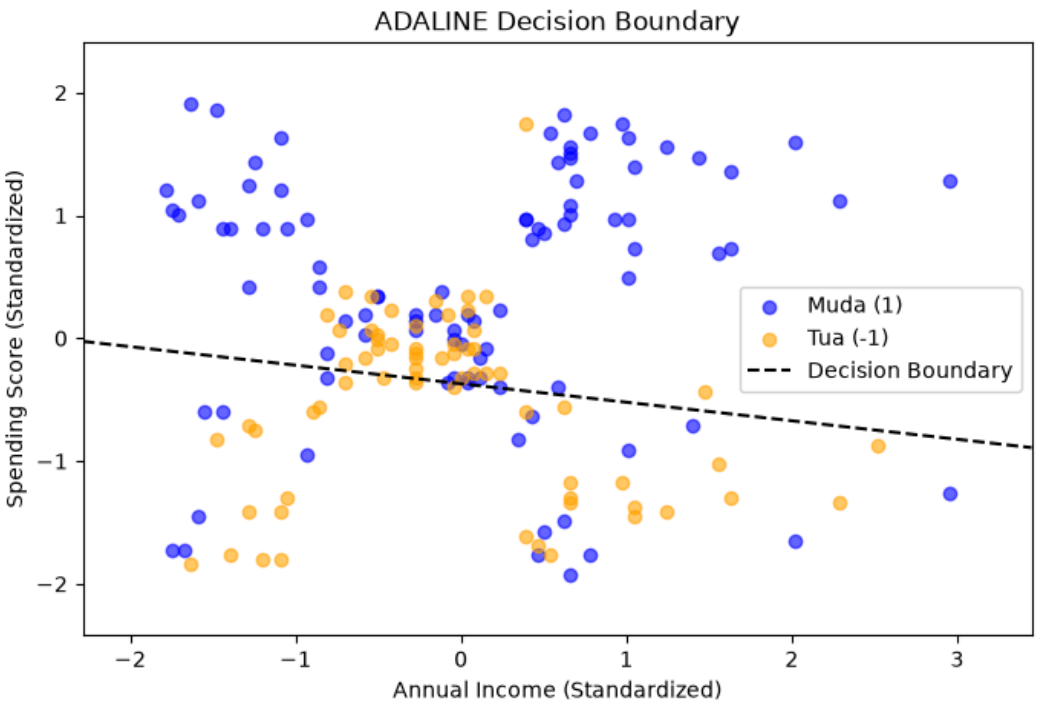


Gambar 5. Kurva Pelatihan Perceptron

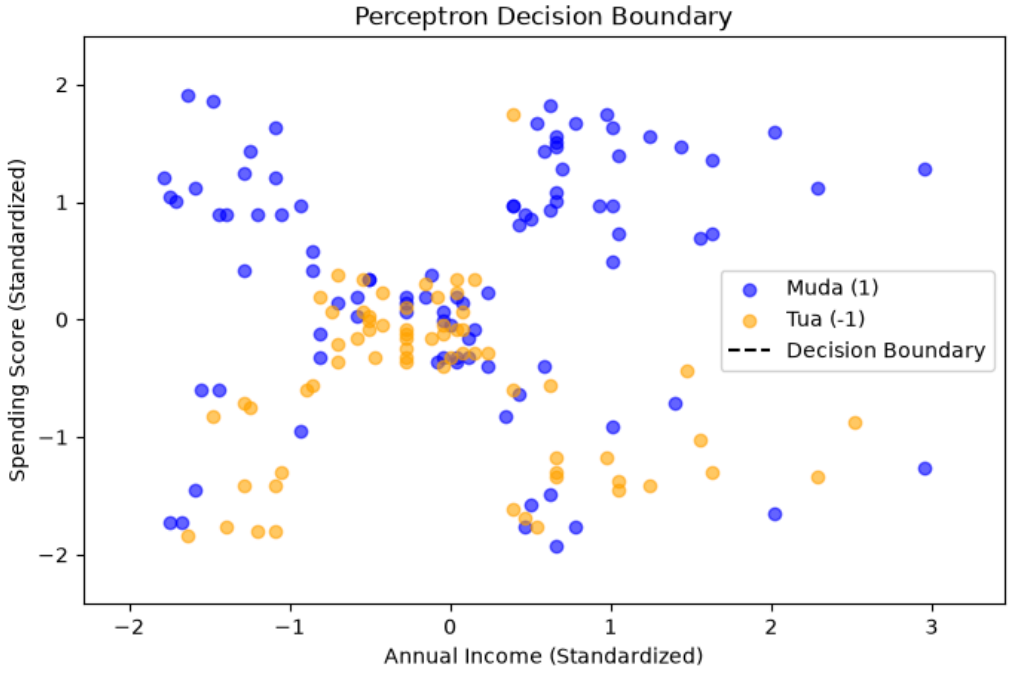


Gambar 5. Kurva Pelatihan ADALINE

Jumlah pembaruan Perceptron turun dari 69 pada epoch pertama lalu berosilasi antara 58 dan 62 mulai sekitar epoch ke-16, sedangkan MSE ADALINE turun dari 1,00 menjadi 0,86 selama 50 epoch.



Gambar 6. Decision Boundary ADALINE



Gambar 7. Decision Boundary Perceptron

Garis keputusan Perceptron ($x_2 \approx 0{,}89 \cdot x_1 + 11{,}5$) berada di luar rentang sumbu sehingga tidak tampak, dan seluruh titik berada pada sisi positif. Garis keputusan ADALINE ($x_2 \approx -0{,}15 \cdot x_1 - 0{,}37$) miring landai ke bawah, dan titik kedua kelas tetap bercampur di kedua sisi garis.

VII. Pembahasan dan Keterbatasan

A. Pembahasan

- **Perceptron**
    1. Perceptron memperbarui bobot dan bias per sampel hanya ketika terjadi salah klasifikasi, dengan error $(y - \hat{y})$ dari keluaran fungsi aktivasi bipolar step
    2. Perubahan learning rate tidak mengubah hasil karena bobot awal nol sehingga η hanya menskalakan bobot. Perceptron tidak kebal terhadap skala fitur: tanpa standardisasi, pembaruan tetap 80-82 (vs 58)
    3. Perceptron menghasilkan tingkat akurasi uji sebesar 57,50% dengan 58 pembaruan akibat salah klasifikasi pada epoch ke-50 . Hal ini mengindikasikan data tidak terpisah secara linear dengan dua fitur ini
    4. Perceptron memprediksi seluruh 40 sampel uji sebagai Muda (+1): 23 benar dan 17 salah, sehingga akurasinya sama dengan baseline kelas mayoritas (57,50%). Kelas Tua tidak terdeteksi sama sekali (recall 0,00; precision dilaporkan 0,00 karena tidak ada prediksi Tua).
- **ADALINE**
    1. ADALINE menggunakan Batch Gradient Descent yang memperbarui bobot berdasarkan penurunan MSE (Mean Squared Error) dari keluaran linier kontinu sebelum dikonversi ke fungsi threshold
    2. ADALINE sangat bergantung pada standardisasi data, karena tanpa standardisasi MSE diverge ($3{,}7 \times 10^{178}$) dan akurasi uji turun ke 42,5%
    3. ADALINE menunjukkan performa klasifikasi yang lebih seimbang dibandingkan Perceptron karena memprediksi kedua kelas, dengan akurasi uji 60% dan MSE terendah 0,7776 ($\eta = 0{,}1$). Tetapi selisih akurasinya dengan Perceptron hanya satu sampel (24 vs 23).
    4. Pada $\eta = 0{,}01$, ADALINE mengenali kedua kelas (recall Muda 0,70; recall Tua 0,47), sehingga ada indikasi model belajar pola, bukan sekadar menebak kelas mayoritas. Namun recall Tua masih di bawah 0,5.

B. Keterbatasan

- Data uji hanya 40 sampel, sehingga satu sampel setara 2,5 poin persentase dan selisih akurasi antara model rentan terhadap pembagian data.
- Hanya satu kali pembagian data (seed 42) tanpa validasi silang, dan pelatihan dibatasi 50 epoch.

- Label dibentuk dari ambang usia 40 tahun, sehingga pelanggan berusia di sekitar 40 sulit dibedakan oleh fitur belanja

C. Perbandingan

- **Keterpisahan linear.** Data tidak menunjukkan indikasi terpisah secara linear: pembaruan Perceptron berosilasi antara 58 dan 62 tanpa mencapai nol (Gambar 5), dan MSE terbaik ADALINE (0,778) hanya sedikit di bawah tebakan konstan (0,974).
- **Penggunaan error.** Perceptron memakai error keluaran ambang ($y - \hat{y}$) hanya pada sampel yang salah, sedangkan ADALINE memakai error linear ($y - z$) dari seluruh sampel.
- **Pengaruh η, epoch, dan standardisasi.** η tidak memengaruhi Perceptron tetapi mempercepat penurunan MSE ADALINE, yang belum konvergen pada $\eta = 0{,}001$ dalam 50 epoch. Tanpa standardisasi, ADALINE diverge.
- **Akurasi sama, proses berbeda.** ADALINE mencapai 60% pada ketiga η dengan MSE berbeda, sedangkan akurasi Perceptron (57,50%) sama dengan baseline mayoritas.
-

VIII. Kesimpulan

- Pada Perceptron, η tidak mengubah hasil karena bobot awal nol, sedangkan pada ADALINE η yang lebih besar mempercepat penurunan MSE tanpa mengubah akurasi uji (60%). Tanpa standardisasi, ADALINE diverge ($\eta = 0{,}01$), sehingga standardisasi penting untuk model berbasis gradien.
- Perceptron memprediksi semua sampel uji sebagai Muda (57,50%, sama dengan baseline kelas mayoritas), sedangkan ADALINE memprediksi kedua kelas (60%). Selisih akurasinya hanya satu sampel, dan recall kelas Tua ADALINE masih rendah (0,47).
- Perceptron memperbarui bobot dari error keluaran ambang pada sampel yang salah, sedangkan ADALINE dari error linear pada seluruh sampel.
- Pembaruan Perceptron berosilasi antara 58 dan 62 tanpa mencapai nol, dan MSE terbaik ADALINE (0,778) tidak jauh di bawah MSE tebakan konstan (0,974), sehingga ada indikasi kedua kelas tidak terpisah secara linear dengan dua fitur ini. Hasil ini terbatas pada 40 data uji dan satu kali pembagian data. Pengembangan berikutnya dapat menambah fitur atau memakai validasi silang.

IX. Daftar Pustaka

Gupta, V., dkk. (2025). Customer segmentation using machine learning. *International Journal of Innovative Research in Technology (IJIRT)*, 11(11). https://ijirt.org/publishedpaper/IJIRT176215_PAPER.pdf

Pedregosa, F., dkk. (2011). Scikit-learn developers. (t.t.). *scikit-learn API reference*. https://scikit-learn.org/stable/api/index.html. (diakses 9 oktober 2026)

Raschka, S. (t.t.). *Adaline: Adaptive linear neuron classifier*. Dokumentasi mlxtend. https://rasbt.github.io/mlxtend/user_guide/classifier/Adaline/ (diakses 9 Oktober 2026)

Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386-408. https://doi.org/10.1037/h0042519

Widrow, B., & Hoff, M. E. (1960). Adaptive switching circuits. *IRE WESCON Convention Record*, Part 4, 96-104. https://isl.stanford.edu/~widrow/papers/c1960adaptiveswitching.pdf